

Fictions juridiques à la française

Mesurer et neutraliser l'hallucination de citations d'articles
dans les assistants juridiques grand public

Wilfred Doré

François Amat

Hackathon Assemblée nationale 2026 — « IA de confiance »

Juillet 2026 — *draft préliminaire*

Résumé

Les assistants à base de grands modèles de langage (LLM) citent des articles de loi avec aplomb, parfois inexistantes ou hors-sujet. Sur le droit américain, ce risque est désormais documenté ; sur le **droit français**, aucun benchmark public ne mesure spécifiquement l'**hallucination de citation d'articles** pour des **questions citoyennes**. Nous proposons un benchmark ancré sur **Canutes/Légifrance** comme vérité-terrain, mesurons le taux d'hallucination d'un panel de modèles (frontier, souverain français, petit modèle exécuté localement), et montrons qu'une **couche de vérification déterministe « fail-closed »** à deux niveaux (existence *et* pertinence) refuse de présenter toute citation non vérifiée, quel que soit le modèle sous-jacent — et nous quantifions que l'existence seule est insuffisante ($\sim 19\%$ des citations sont des articles réels mais hors-sujet). Nous formalisons cette couche comme des **garanties exécutables** : une source de vérité unique, partagée entre le code d'exécution, les tests et l'interface. Un résultat pilote ($n = 12$) fait apparaître un *paradoxe frugalité/souveraineté* : le modèle que l'on choisirait pour une inférence locale et souveraine est aussi celui qui hallucine le plus, ce qui rend la vérification non pas optionnelle mais constitutive de la confiance.

1 Introduction

L'accès des citoyens au droit est un enjeu démocratique. Un assistant qui répond « la durée légale du travail est fixée par l'article X » n'est utile que si l'article X existe et dit bien cela. Or un numéro d'article faux n'est pas une imprécision bénigne : il envoie le citoyen vers une norme qui ne le concerne pas. La littérature récente rapporte des taux d'hallucination de citations juridiques de l'ordre de 58 à 88 % selon les tâches [1, 8].

Nous distinguons trois niveaux d'intervention, unifiés par une couche de confiance : le **modèle** (quel LLM, à quel taux d'erreur), le **moteur d'inférence** (portabilité, souveraineté logicielle) et le **silicium** (frugalité, souveraineté matérielle). Nos contributions :

1. un **benchmark français** de citation d'articles ancré sur Canutes/Légifrance ;
2. une **mesure comparative** frontier vs souverain français vs petit modèle local ;
3. une **couche de vérification** et des **garanties exécutables** ramenant l'hallucination présentée à ≈ 0 , et son évaluation.

2 Travaux liés

Hallucinations juridiques (US). Magesh, Surani, Dahl *et al.* documentent les hallucinations des systèmes RAG juridiques sur le droit américain [1]. Nous nous positionnons comme le pendant

français et *grand public*. **Détection de citations.** *Who Checks the Citations?* [2] et *LegalCite-Bench* [3] évaluent la détection/vérification de citations, principalement en anglais. **Droit français.** La détection de citations implicites du Code civil dans les décisions de justice via Judilibre [4] traite d’une tâche différente : *détection* des citations dans des *décisions*, non *mesurer l’hallucination générative* sur des *questions citoyennes* ancrées sur les *codes*. **Benchmarks généraux.** LegalBench (US) et LEXTREME (UE) [5] ne comportent pas de tâche dédiée à la citation d’article en droit français grand public. **Écart.** À notre connaissance, aucun travail ne mesure l’hallucination de citation d’article pour des questions citoyennes en droit français avec Canutes/Légifrance comme vérité-terrain, ni n’évalue une couche de vérification « fail-closed » par-dessus.

3 Méthode

3.1 Construction du benchmark

Chaque item associe une **question citoyenne** à un ou plusieurs **articles de référence**. La vérité-terrain est fournie par **Canutes** (table `legifrance.article`, statut `VIGUEUR`, identifiant `LEGIARTI`), ce qui rend la construction automatisable à grande échelle. Pour le passage à l’échelle ($n \geq 100$), des gisements de questions réalistes existent dans les données ouvertes parlementaires elles-mêmes : Canutes contient **292 746 questions parlementaires du Sénat** (`senat.questions`, comptage effectué sur l’instance du hackathon), et les *questions écrites et orales de l’Assemblée nationale au Gouvernement* sont disponibles parmi les ressources officielles. Les réponses ministérielles citant les textes applicables, elles fournissent des paires question–articles de référence vérifiables dans Canutes. Métriques : proportions de réponses *correcte* / *hallucination* (citation erronée) / *sans citation*, avec un score *exact-match* sur le couple (code, numéro). Un numéro proche mais faux (p.ex. 413-3 pour 414) compte comme hallucination : suivre le mauvais article induit le citoyen en erreur.

3.2 Pipeline de vérification (fail-closed)

question → génération → extraction → vérification → réponse sourcée ou refus.

On ne présente que ce qui est vérifié ; en cas de doute, on refuse plutôt que d’inventer. La vérification a **deux niveaux**, car l’existence ne suffit pas : (i) *existence* — l’article existe-t-il, en vigueur, dans le bon code (identifié par son identifiant stable Légifrance, non par simple correspondance de chaîne) ? (ii) *pertinence* — le **texte réel** de l’article, récupéré dans Canutes, soutient-il la question ? Ce second niveau est *ancré* : un vérificateur lit la source primaire, il ne juge pas de mémoire. **Constat empirique** : sur notre pilote, la vérification d’existence seule laisse passer ~19 % des citations — des articles *réels mais hors-sujet*, rendus crédibles par un vrai lien — que seule la pertinence rejette.

3.3 Garanties exécutables

Les invariants de confiance (zéro citation inventée présentée ; refus si aucune source vérifiable ; chaque citation renvoie à Légifrance) sont encodés dans une **fonction unique** utilisée au **runtime**, dans les **tests BDD/Gherkin** et dans l’**interface**. La confiance ne se décrète pas : elle s’exécute et se teste. Cette approche relève de la *vérification à l’exécution* et de la *spécification exécutable* : la contribution ne tient pas au choix d’implémentation (une fonction Python plutôt que des scénarios Gherkin), mais au **principe d’une source de vérité unique** des invariants — simultanément

vérifiée en production, testée, et rendue visible à l'utilisateur — appliquée au cas de la citation juridique.

4 Résultats préliminaires

Étude pilote : $n = 12$ questions de droit du travail, civil, pénal et de la consommation, vérité-terrain hand-curée (à re-vérifier systématiquement dans Canutes). Un seul run, température 0,2. Panel interrogé via une API OpenAI-compatible et un modèle local (Ollama, Mistral 7B, sur MacBook M2 Pro).

Modèle	Citation correcte
claude-sonnet-4-5	12/12 (100 %)
mistral-large-3 (souverain FR)	12/12 (100 %)
mistral-small-24B	11/12 (92 %)
gpt-4o	10/12 (83 %)
gemini-2.5-flash	10/12 (83 %)
mistral 7B (local, Ollama)	2/12 (17 %)
Le Rapporteur (existence + pertinence) 0 % de citation non vérifiée présentée	

TABLE 1 – Taux de citation correcte par modèle (pilote, $n = 12$).




FIGURE 1 – Répartition correcte / hallucination / sans citation par modèle, et effet de la couche de vérification (hallucination présentée nulle).

Trois lectures : (i) même les modèles frontier hallucinent le droit français ; (ii) le modèle souverain français est compétitif avec le meilleur du panel ; (iii) **paradoxe frugalité/souveraineté** : le petit modèle exécuté localement, idéal pour une inférence souveraine et frugale, hallucine le plus (10/12). La vérification est donc *ce qui rend* une IA juridique locale digne de confiance.

4.1 Évaluation de la couche de vérification

Nous rejouons les 72 réponses du panel à travers la couche de vérification, en comparant trois politiques. Une réponse est *présentée* si toutes ses citations passent la politique, sinon *refusée*.

Politique	Halluc. présentée	Correct présenté	Sur-refus
Aucune vérification (LLM seul)	15/72 (21 %)	57/72	—
Existence seule (correspondance de chaîne)	14/72 (19 %)	—	—
Existence (CID exact) + pertinence ancrée	2/72 (3 %)	52/72 (72 %)	5/72 (7 %)

TABLE 2 – Effet de la politique de vérification sur les 72 réponses du pilote. L’existence seule n’attrape presque rien (1 hallucination sur 15 : les 14 autres citaient des articles réels mais hors-sujet). La vérification complète divise l’hallucination présentée par 7, au prix d’un sur-refus de 7 % — un compromis assumé (fail-closed : mieux vaut un refus qu’un faux).

Deux enseignements méthodologiques : (a) le **match du code par identifiant stable** (CID) plutôt que par correspondance de chaîne est indispensable — un « article 9 » existe dans des dizaines de codes, et le filtre textuel initial faisait chuter le correct présenté à 35 % (sur-refus 44 %) en résolvant de mauvais articles ; (b) les 2 hallucinations restantes sont des citations plausibles du bon domaine, que seule une pertinence plus fine (au-delà d’un juge unique) attraperait.

5 Discussion : souveraineté et frugalité

La couche de vérification étant *model-agnostique*, elle autorise des choix souverains à chaque niveau : moteur portable (le même code d’inférence vise NVIDIA, AMD, Apple Silicon) et silicium non-NVIDIA (accélérateurs d’inférence dédiés). La frugalité de ces accélérateurs est documentée par ailleurs [6], tout comme la portabilité des moteurs modernes [7]. Le message tient en une phrase : *on ne fait confiance à aucun modèle, on vérifie* — ce qui débloque précisément les déploiements frugaux et locaux.

6 Limites et travaux futurs

$n = 12$, vérité-terrain hand-curée, un seul run : il faut **élargir à $n \geq 100$** ancré sur Canutes, plusieurs exécutions, intervalles de confiance, versions de modèles figées. Étendre au-delà de la citation exacte (validité temporelle, abrogations, renvois). Un comparatif matériel *apples-to-apples* (même modèle sur NVIDIA / AMD / Qualcomm en serveur, Apple Silicon / Snapdragon X Elite en bureau) reste à mener.

7 Conclusion

Nous esquissons le premier benchmark d’hallucination de citations d’articles pour le droit français grand public, et montrons qu’une vérification déterministe fail-closed, exprimée comme des garanties exécutables, refuse de présenter toute citation non vérifiée. Le résultat le plus contre-intuitif — les modèles les plus souhaitables pour la souveraineté frugale sont les plus faillibles — fait de la vérification une brique constitutive, non accessoire, d’une IA juridique de confiance.

Références

- [1] V. Magesh, F. Surani, M. Dahl *et al.*, *Hallucination-Free ? Assessing the Reliability of Leading AI Legal Research Tools*, Journal of Empirical Legal Studies, 2025.
- [2] *Who Checks the Citations ? Benchmarking Legal Hallucination Detection*, arXiv :2606.21155, 2026.
- [3] *LegalCiteBench : Evaluating Citation Reliability in Legal Language Models*, arXiv :2605.10186, 2026.
- [4] *Detecting Implicit Legal Citations in French Court Decisions*, arXiv :2603.22973, 2026.
- [5] J. Niklaus *et al.*, *LEXTREME : A Multi-Lingual and Multi-Task Benchmark for the Legal Domain*, 2023.
- [6] UCSD, *Energy efficiency of the Qualcomm Cloud AI 100 for LLM inference*, arXiv :2507.00418, 2026.
- [7] *Portable GPU kernels in Mojo across CUDA and HIP*, arXiv :2509.21039, 2025.
- [8] *LLM Hallucination Statistics 2026*, SQ Magazine, 2026.